维护周报-20261019

Kubeflow AI 平台运行周报

- 报告周期： 2026 年 10 月 12 日 - 2026 年 10 月 19 日
- 运维负责人： unix

本周重点： 9 月曾判定闭环的 GPU 掉总线故障（Xid 79）于 10 月 19 日 21:23（CST）复发。worker-node01 第二张 RTX PRO 6000（PCI 98:00.0，UUID GPU-e24defb2-…）被 device-plugin 标为 unhealthy，节点 GPU allocatable 由 2 降至 1；GPU0 上的 qwen38-27b-mtp 仍正常运行，主机未重启（uptime 33 天）。同期 user3 pengwin 训练活跃，node02 两张 3090 满载；10 月 14 日 node02 出现 Ready 条件翻转（主机未重启，疑似 kubelet 级恢复）。

1. 集群健康度概览 (Cluster Health Summary)

本模块用于给领导层快速浏览，展示系统整体稳定性。

- 集群可用率 (SLA)：约 99.9%+（无整节点宕机；10/14 node02 Ready 条件翻转，Prometheus node_boot_time 未变，属非整机重启事件，精确中断时长本周期事件已滚动丢失）
- 节点状态：3/3 Ready（Master x1, Worker x2）
- 核心组件状态：
- Kubernetes 控制平面 (v1.32.10)：[OK] 正常
- Kubeflow Dashboard：[OK] 正常（约 7 天前重建后 Running）
- Istio 网关：[OK] 正常
- 监控系统 (Prometheus/Grafana)：[OK] 正常（已稳定 176 天）
- 存储供给 (local-path-provisioner)：[OK] 正常
- 镜像仓库 (Harbor 代理缓存)：[OK] 正常（6 个代理项目在线，仓库 227 / 188.46 GB）
- GPU 驱动：[!] 异常 — node01 GPU1 报 Xid 79 后不可用；GPU0 正常；node02 四卡可见

2. 资源消耗统计 (Resource Utilization)

展示硬件利用率，帮助客户判断是否需要扩容。

资源类型	峰值利用率	高峰期平均利用率	高峰期剩余可用量
CPU	~3.9%	~1.9%	约 215 核
内存	~12.5%	~9.1%	约 0.57 TiB
GPU (NVIDIA)	100%	~4.0%	调度可用约 4 张（node01 仅剩 1 张可分配）
存储 (PVC)	~9.7%	~8.5%	Bound 6.65 TiB；Released 仍占 9.22 TiB

节点详情：

节点	角色	CPU	GPU	当前 Pod 数
master-node-storage-r620-g40	control-plane	56c	0	21
worker-node01-pro6000	worker	128c	2x RTX PRO 6000（allocatable=1）	118
worker-node02-3090	worker	40c	4x RTX 3090	22

即时资源（kubectl top，非周期峰值）：master CPU 2% / 内存 22%；node01 CPU 2% / 内存 15%；node02 CPU 6% / 内存 50%。

GPU 实测（巡检时）：

节点	GPU	显存	利用率	温度	状态
node01	GPU0 38:00.0	90844 MiB	~0%	29	正常，承载 qwen38-27b-mtp
node01	GPU1 98:00.0	—	—	—	Xid 79，device handle Unknown Error，unhealthy
node02	GPU0 / GPU3	18097 MiB	96–100%	70–71	训练带载中
node02	GPU1 / GPU2	0 MiB	0%	26–30	空闲

- 负载倾斜方向反转：上期 node02 107 Pod / node01 30 Pod；本期变为 node01 118 / node02 22（与 10/14 Ready 翻转后的重调度一致）
- 存储：Bound PVC 53 个 / 6805 GiB（较上期 +10 个 / +530 GiB）；Released PV 仍为 178 个 / 9444 GiB，未回收
- 磁盘水位：node02 根分区 75.0%（上期 74.8%），/home/data 77.9%（上期 77.6%），缓慢上升

3. AI 业务运行数据 (AI Workflow Stats)

体现 Kubeflow 平台的实际产出。

- Notebook 运行数：本周活跃 6 个，状态 Running
- kubeflow-user-example-com/style-big、kubeflow-user-example-com/vs
- user2-example-com/mni-test-0104、user2-example-com/mni-test-qw-260106
- user4-example-com/awgs-builder、user5-example-com/csj-spine-detection
- Pipeline / Workflow：user3 pengwin 系列本周期高度活跃
- 周期内在 node01 完成多轮 smoke/train（overfit、fragment-b、surface-refine 等，状态 Succeeded）
- 周期末 pengwin-task3-beta-20261019-v1-smoke（10/19 20:53 CST 起）在 node01 跑完后约 30 分钟，同节点 GPU1 出现 Xid 79
- node02 上 3gpu 相关任务出现多条 Failed（业务侧训练/检查失败，非平台基础设施整体宕机）
- 说明：10/20–10/21 仍有续跑与重试（属周期外，仅作背景）
- KServe 模型推理：在线模型 2 个，Ready
- qwen38-27b-mtp（持续带载 GPU0）
- detect-digits-2
- 本周期新建业务 PVC 约 10 个（均为 user3 pengwin 相关，5–100 GiB）
- radar-inference-api-v2：仍为 0 副本，配套 PVC/Service/NodePort 未回收

4. 故障处理与告警记录 (Incidents & Alerts)

展示你的专业性，以及你解决了哪些隐患。

4.1 【严重】GPU Xid 79 复发（worker-node01 GPU1）

现象： 10 月 19 日 21:23:47 CST，nvidia-device-plugin 连续上报

XidCriticalError: Xid=79，设备 GPU-e24defb2-8a82-10d2-2b8e-bf8988e55f2f 被标记 unhealthy。

证据：

- kubectl logs -n gpu-operator nvidia-device-plugin-daemonset-…：I1019 13:23:47 … Xid=79 … marking device as unhealthy（UTC）
- nvidia-smi -L：Unable to determine the device handle for gpu 0000:98:00.0: Unknown Error
- 节点 nvidia.com/gpu：capacity=2，allocatable=1
- gpu-feature-discovery：CrashLoopBackOff，日志 error getting device handle for index '1': Unknown Error（已累计重启 485 次）
- 主机 未重启：Prometheus node_boot_time 仍为 2026-09-18；Ready 起始时间仍为 9/18

影响：

- node01 可调度 GPU 减半，新的单卡/双卡训练无法再占用第二张卡
- GPU0 上 qwen38-27b-mtp 未中断（显存 90.8 GB，ECC 未修正错误仍为 0）
- 与 9/10、9/11 为同一类故障（Xid 79 掉总线），且仍是 PCI 98:00.0 这张卡；此前“24 天零 Xid 闭环”结论需撤回，改为硬件隐患未根除

关联时间线：

时间 (CST)	事件
09-10 / 09-11	首次连续两天 Xid 79，节点异常重启
09-18	计划内维护约 66 分钟
09-18 ~ 10-19 白天	约 31 天无 Xid 记录（单卡/空载为主）
10-19 20:53	pengwin-task3-beta-…-smoke 调度至 node01
10-19 21:23	GPU1 报 Xid 79，device-plugin 置 unhealthy
巡检时 (10-21)	GPU1 仍不可用；GPU0 正常；节点未重启

建议：

1. 优先安排现场硬件复检（电源/PCIe 插槽/转接板/线缆），重点针对 98:00.0 槽位；调取 BMC/iDRAC SEL
2. 在硬件处置前，避免再向 node01 调度第二张 GPU 任务；需要双卡时优先 node02 或等修复
3. 配置基于 device-plugin / DCGM 的 Xid 即时告警（上周已建议，仍未落地）
4. 修复后做一次受控双卡满载验证，再恢复“可闭环”判断

4.2 【警告】worker-node02 Ready 条件于 10/14 翻转

现象： Ready lastTransitionTime = 2026-10-14T03:20:45Z（11:20 CST）；Memory/Disk/PID Pressure 同步翻转。

证据： Prometheus 三节点 node_boot_time 在本周期内均未变化（node02 开机仍为 2026-05-09），故不是整机重启；更可能是 kubelet 短暂不可用后恢复。周期内 Warning Events 已滚动，未能还原精确 downtime。

影响： 工作负载重调度，Pod 分布由“偏 node02”翻转为“偏 node01”（118 vs 22）。

建议： 排查 10/14 前后 node02 的 kubelet/containerd 日志（需主机权限）；观察是否再现。

4.3 【警告】常规告警与遗留问题

当前 firing 约 5 条（周期内平均约 4、峰值曾到 47，与 GPU 事件窗口相关）：

告警	级别	说明
Watchdog	none	监控自检，非故障
KubeMemoryOvercommit	warning	request 超配，实际内存约 9%，暂无风险
KubePodNotReady	warning	spline-yolov8-train 持续 ImagePullBackOff

告警	级别	说明
KubePodCrashLooping	warning	gpu-feature-discovery（由 GPU1 掉卡引起）
KubeDaemonSetRolloutStuck	warning	与 gpu-operator 侧异常相关

遗留跟踪：

问题	分级	状态
GPU Xid 79 / GPU1 不可用	严重	本期新发（复发）
spline-yolov8-train 缺镜像	警告	持续（Pod 年龄约 7 天为重建后计数；任务已存续百余天）
178 Released PV / 9.22 TiB	警告	无变化，未回收
qwen36-cache 120 GiB 孤儿卷	提示	Bound 112 天，无挂载
radar-* 零副本 + 200 GiB	提示	仍停用未清理
node02 磁盘 75% / data 78%	提示	缓慢上升，建议镜像 GC
证书剩余约 66 天	警告	12/26 到期，轮换窗口紧迫

4.4 镜像源治理复核

- local-path helper 仍指向 172.16.1.72:30002/library/busybox
- Kyverno inject-kaniko-registry-mirror Ready（56 天）
- Harbor 代理项目齐全；本周期无因外网源导致的新增 ImagePullBackOff（业务私有镜像除外）

5. 数据备份与安全巡检 (Backup & Security)

让客户对数据资产放心。

- Velero：本周期窗口内可见 15 次全部 Completed、0 errors
- pvc-daily 6 次、minio-daily 8 次、kubeflow-weekly 1 次（pvc-daily TTL 168h，更早副本已按策略过期，属正常）
- 最近：minio-daily-backup-20261019040018、pvc-daily-backup-20261019030018
- MinIO 模型数据备份：[OK] 正常
- K8s 证书：剩余约 66 天（2026-12-26 到期）
- [!] 上期建议的 10 月排期仍未落实，距到期不足 10 周，应立即确定轮换窗口
- 镜像扫描：Harbor Trivy 在线，本周未做主动全量扫描

6. 下周工作计划 (Next Week's Plan)

- 暂无安排

- 报告生成时间：2026-10-21 10:25 CST
- 数据来源：kubectl（只读）、Prometheus API、Velero CR、Harbor API、nvidia-smi（经已有 dcgm-exporter Pod）、gpu-operator 组件日志、openssl
- 证据目录：/home/storage/k8s-weekly-inspection/output/evidence-20261019/
- 缺失项：本周期未创建诊断 Pod，故未直接读取节点 kern.log；Xid 结论以 device-plugin 日志与 nvidia-smi 为准。10/14 node02 Ready 翻转的精确中断秒数因 Events 滚动未能还原。