维护周报-20261026

Kubeflow AI 平台运行周报

- 报告周期： 2026 年 10 月 19 日 - 2026 年 10 月 26 日
- 运维负责人： unix

本周重点： 本周期发生一次全平台短时中断：10 月 23 日 14:16 worker-node01 整机重启（用于恢复 10/19 再次掉卡的 GPU1），由于平台组件几乎全部集中在该节点，Kubeflow Dashboard 中断约 11 分钟、qwen38 推理中断约 12 分钟、Pipelines API 中断约 16 分钟。

GPU1 已恢复并带载运行 3 天、无新 Xid，但这是 6 周内第 3 次 Xid 79，且本次重启仅约 3 分钟、驱动未变更，未见硬件处置迹象，隐患仍在。

新取证显示 10/19 掉卡前约 1.5 分钟内，GPU1 功耗由空闲的 33 W 骤升至 516 W，供电瞬态方向的嫌疑上升。

1. 集群健康度概览 (Cluster Health Summary)

本模块用于给领导层快速浏览，展示系统整体稳定性。

- 集群可用率 (SLA)：约 99.90%（按 Kubeflow 入口计，统计至 10/26 18:00；10/23 node01 重启致 Dashboard 中断约 11 分钟）
- 节点状态：3/3 Ready（Master x1, Worker x2）；worker-node01 于 10/23 14:19 重启，NotReady 约 3 分钟
- 核心组件状态：
- Kubernetes 控制平面 (v1.32.10)：[OK] 正常（本周期 apiserver / controller-manager / scheduler / etcd 无重启）
- Kubeflow Dashboard：[!] 10/23 中断约 11 分钟，当前正常
- Istio 网关：[!] 10/23 中断约 5 分钟，当前正常（单副本，位于 node01）
- 监控系统 (Prometheus/Grafana)：[OK] 正常（已稳定 182 天；数据保留期仅 10 天）
- 存储供给 (local-path-provisioner)：[OK] 正常（10/23 随 node01 重启一次，已恢复）
- 镜像仓库 (Harbor 代理缓存)：[OK] 正常（健康检查全部组件 healthy；10/23 中断约 5 分钟）
- GPU 驱动：[!] node01 GPU1 于 10/19 21:23 再次 Xid 79，10/23 重启后恢复；当前 6 卡在线，驱动 580.126.09 / 580.95.05 未变更

2. 资源消耗统计 (Resource Utilization)

展示硬件利用率，帮助客户判断是否需要扩容。

资源类型	峰值利用率	高峰期平均利用率	高峰期剩余可用量
CPU	~4.0%	~2.6%	约 215 核
内存	~10.3%	~8.7%	约 0.58 TiB
GPU (NVIDIA)	100%	~24.9%	约 3 张（6 张中 3 张被调度占用）
存储 (PVC)	~9.4%	~8.7%	已供给 6.84 TiB；另有 Released 9.22 TiB 待回收

节点详情：

节点	角色	CPU	GPU	当前 Pod 数
master-node-storage-r620-g40	control-plane	56c	0	21

节点	角色	CPU	GPU	当前 Pod 数
worker-node01-pro6000	worker	128c	2x RTX PRO 6000 Blackwell (96GB)，可分配 2/2	117
worker-node02-3090	worker	40c	4x RTX 3090 (24GB)，可分配 4/4	21

GPU 实测（巡检时 10/26 18:00）：

节点	GPU	显存占用	利用率	功耗	温度	负载
node01	GPU0 38:00.0	90028 MiB	0%	83 W	30°C	qwen38-27b-mtp
node01	GPU1 98:00.0	14876 MiB	21%	300 W	46°C	user3 训练任务
node02	GPU0-3	0 MiB	0%	25-29 W	26-30°C	空闲（csj-spine-detection 调度占用 1 张但无进程）

- GPU 平均利用率由上期 ~4.0% 升至 ~24.9%，来自 user3 训练任务与 qwen38 推理；node01 GPU0 在 10/26 下午多次达到约 600 W（满功耗）
- 即时资源（kubectl top，非周期峰值）：master CPU 1% / 内存 23%；node01 CPU 3% / 内存 12%；node02 CPU 1% / 内存 51%
- 磁盘：node02 根分区 75.0%、/home/data 77.9%（与上期持平）；node01 38.2%；master 48.8%
- 存储：PV 共 233 个 / 16449 GiB。Bound 55 个 / 7005 GiB（较上期增加 2 个 / 200 GiB）；Released 178 个 / 9444 GiB，仍未回收
- 负载倾斜未改善：node01 117 个 Pod，node02 仅 21 个。这一格局在 10/23 已从"不均衡"变成了实际的故障放大因素，见 4.1

3. AI 业务运行数据 (AI Workflow Stats)

体现 Kubeflow 平台的实际产出。

- Notebook 运行数：注册 9 个，活跃 6 个，全部 Running
- node02：kubeflow-user-example-com/style-big、kubeflow-user-example-com/vs、user5-example-com/csj-spine-detection
- node01：user2-example-com/mni-test-0104、user2-example-com/mni-test-qw-260106、user4-example-com/awgs-builder
- user2 的 2 个 Notebook 在 10/23 14:19 随 node01 重启中断（容器重启，内存中的会话状态丢失）
- Pipeline 运行数：周期内启动 42 次，成功 38 次，失败 2 次，错误 2 次（成功率约 90%），全部来自 user3
- user3 另以裸 Pod 方式提交大量实验任务：周期内新建 Pod 175 个，成功 140、失败 31、运行中 4
- 31 个失败均为业务程序退出码 1，无 OOMKilled、无驱逐、无一例由 10/23 重启导致，属业务侧问题
- KServe 模型推理：在线模型 2 个，全部 Ready
- qwen38-27b-mtp：10/23 中断约 12 分钟后由新 Pod 恢复，当前带载 node01 GPU0
- detect-digits-2
- 新增业务数据卷 4 个，共 400 GiB（user3 的 pengwin-task3-beta-*、pengwin-of-ab-* 输入/结果卷）
- radar-inference-api-v2：仍为 0 副本，配套资源未回收

4. 故障处理与告警记录 (Incidents & Alerts)

展示你的专业性，以及你解决了哪些隐患。

4.1 【严重】10/23 node01 重启引发全平台短时中断

现象： 10 月 23 日（周五）14:16 worker-node01
整机重启，平台入口、登录、镜像仓库、Pipelines、模型推理、日志等服务同时中断，14:21 起陆续恢复，最慢的 Loki 于 14:51 恢复。

证据：

- 重启时刻：Prometheus node_boot_time 显示 node01 内核于 14:19:37 启动；node-exporter 14:17-14:20 无数据；Ready 条件 14:18-14:20 为 False
- 重启性质：device-plugin 日志 14:16:34 记录 Received signal "terminated", shutting down，为有序关机，与 9 月两次异常宕机不同，判断为人为发起的重启；重启前节点未 cordon / drain（kube_node_spec_unschedulable 全程为 0）
- 影响面：node01 上 dex、cert-manager、Harbor 全套、Istio（istiod / 入口网关 / cluster-local-gateway）、Knative、Kubeflow 全部控制器与 Web 应用、Kyverno、Loki、Velero 及其 MinIO、metrics-server 等容器均在 14:19 重启

各服务恢复时刻（自 14:16 起算）：

服务	恢复时刻 (CST)	中断时长
dex 登录认证	14:20:20	约 4 分钟
Harbor 镜像仓库	14:21:09	约 5 分钟
Istio 入口网关	14:21:14	约 5 分钟
Kubeflow Dashboard	14:27:14	约 11 分钟
qwen38-27b-mtp 推理	14:28:55	约 12 分钟
Pipelines API / Profiles	14:32:40	约 16 分钟
Loki 日志	14:51:34	约 35 分钟

- qwen38 恢复偏慢的原因：重启后 kubelet 重新接纳旧 Pod 时 GPU 插件尚未注册，旧 Pod 被拒绝（UnexpectedAdmissionError: no healthy devices present），由 ReplicaSet 新建 Pod 并重新加载模型，耗时约 7 分钟

影响： 一次单节点重启造成整个平台约 11-16 分钟不可用。根因是平台组件高度集中：全集群 159 个 Running Pod 中 117 个在 node01，且入口网关、dex、Harbor、Dashboard、Pipelines 等关键组件均为单副本。另外，由于 containerd 已把 docker.io / gcr.io 统一指向 Harbor 且这两个上游被墙，Harbor 中断期间这两类镜像在全集群都无法拉取。

建议：

1. 关键平台组件跨节点部署：对 Istio 入口网关、dex、Harbor core / registry、centraldashboard、ml-pipeline 设置 2 副本，并配置反亲和或 topologySpreadConstraints 与 PDB

2. 短期在低峰期对 node01 上的无状态平台组件滚动重启，促使调度器向 node02 回迁（node02 当前 21 个 Pod）

3. 恢复 GPU 等需要重启节点的操作纳入变更流程：提前通知、先 cordon / drain、选择低峰期窗口

4.2 【严重】GPU 掉总线（Xid 79）隐患仍未根除

现象： 10 月 19 日 21:23:47，node01 GPU1（PCI 98:00.0，UUID GPU-e24defb2-…）报 Xid 79 后不可用，节点 GPU 可分配数由 2 降为 1，直至 10/23 重启后恢复，不可用时长约 3 天 17 小时。这是 6 周内第 3 次：9/10 GPU0、9/11 GPU1、10/19 GPU1。

证据：

- device-plugin 上一个容器实例日志：10/19 21:23:47 起连续报 XidCriticalError: Xid=79，此后直到 10/23 14:16 停止前无其它 Xid；重启后的新实例至巡检时无任何 Xid

- Prometheus：DCGM_FI_DEV_XID_ERRORS 在 10/19-10/23 对 node01 gpu=1 取值 79；节点 GPU capacity - allocatable 在 10/19 21:30 至 10/23 14:00 大于 0
- 期间 gpu-feature-discovery 持续 CrashLoopBackOff（累计重启 1094 次），10/23 重启后恢复
- 恢复方式只是重启：停机约 3 分钟、驱动版本未变、无 cordon 记录，不具备现场检修硬件的条件

新发现：故障发生在负载突增阶段，而非长时间满载之后。 10/19 21:22:15 之前 GPU1 处于空闲（33 W、22°C、显存 13 MiB）；21:22:30 有任务开始使用 GPU1，功耗跳至 375 W；21:23:30 功耗 516 W、温度 68°C、利用率 95%；17 秒后报 Xid 79。同时刻 GPU0 稳定在 83 W，整机 GPU 总功耗约 600 W，远低于双卡 1200 W 的设计值。（21:24 之后 DCGM 对 GPU1 的读数恒定为 496 W / 81°C，判断为掉卡后的无效值，未计入分析。）

这一形态更符合 GPU1 所在槽位的供电瞬态响应或接插件问题，而非电源总功率不足。

重启后验证情况： 10/23 14:22 至巡检时约 76 小时，双卡同时带载约 40 小时，但双卡同时高功耗（均超过 250 W）仅约 12 分钟。高负载工况的验证样本仍不足，结合历史间隔（9/18 维护后 31 天复发），不能据此判定已修复。

影响： GPU1 不可用期间 node01 可调度 GPU 减半；更重要的是每次恢复都需要重启 node01，而在 4.1 所述的单点格局下，这等同于一次全平台中断。

建议：

1. 安排现场硬件复检，重点 GPU1（98:00.0）槽位：12V-2x6 供电接头与线缆、PCIe 插槽 / 转接卡、电源模块冗余状态；调取 BMC/iDRAC SEL，核对 10/19 21:23 前后的电源与 PCIe 事件
2. 硬件处置前的临时缓解：评估为 node01 两张卡设置功耗上限或锁定频率，降低负载阶跃时的瞬态冲击（需节点 root 权限，按变更流程审批）
3. 落地 GPU 告警（已连续三期建议，至今集群中无任何 GPU 相关告警规则）。以下两条表达式已用 10/19 事件回测，均可在故障后数分钟内触发：
   - max by (Hostname, gpu) (DCGM_FI_DEV_XID_ERRORS) > 0
   - kube_node_status_capacity{resource="nvidia_com_gpu"} - kube_node_status_allocatable{resource="nvidia_com_gpu"} > 0
4. 再次出现掉卡时，按 4.1 建议先 cordon / drain 再重启

4.3 【警告】metadata-writer 持续崩溃

现象： kubeflow/metadata-writer 本周期重启 115 次（约每 1.6 小时一次），当前 Pod 自 10/14 创建以来累计 130 次。前几期报告将该计数视为"历史累计值、当前稳定"，判断有误，在此更正。

证据： 最近一次退出前日志：metadata_writer.py line 185: os.remove(debug_paths.popleft()) 抛出 FileNotFoundError，即组件清理自己写入 /tmp 的调试文件时，遇到文件已不存在便直接退出。user3 流水线越活跃，Pod 事件越多，触发越频繁。

影响： 每次崩溃期间的 Pod 事件不会被写入 ML Metadata，主要影响 KFP v1 风格任务的元数据血缘记录；当前业务以 v2 结构（driver / impl）为主，Pipeline 运行本身不受影响（本周期成功率约 90%）。

建议： 随 KFP 版本升级修复；如短期需要，可对该删除逻辑做容错处理后替换镜像（属变更，需审批）。

4.4 告警汇总

周期内触发过的告警（不含 Watchdog / InfoInhibitor），当前 firing 3 条（Watchdog、KubeMemoryOvercommit、spline 的 KubePodNotReady），无 critical 级别：

告警名称	级别	对象	时段 (CST)	关联事件
KubePodCrashLooping	warning	gpu-operator/gpu-feature-discovery	10-19 21:45 ~ 10-23 14:25	GPU1 掉卡

告警名称	级别	对象	时段 (CST)	关联事件
KubeDaemonSetRolloutStuck	warning	gpu-operator/gpu-feature-discovery	10-19 21:45 ~ 10-23 14:18	GPU1 掉卡
KubeAggregatedAPIDown	warning	v1beta1.metrics.k8s.io	10-23 14:24 ~ 14:29	node01 重启
KubeDeploymentReplicasMismatch	warning	kubeflow 下 6 个 Deployment 及 user2 ml-pipeline-ui-artifact	10-23 14:33	node01 重启
KubeStatefulSetReplicasMismatch	warning	logging/loki	10-23 14:33 ~ 14:52	node01 重启
KubeDaemonSetRolloutStuck	warning	logging/fluent-bit	10-23 14:41 ~ 14:53	node01 重启
KubeContainerWaiting	warning	user3 两个 pengwin-of-ab-formal-* Pod	10-25 02:50 ~ 10-26 05:00，各约 23 小时	业务侧，Pod 已删除，原因无法追溯
KubePodNotReady	warning	user3 5 个 pengwin-task3-*-check Pod	10-19 22:10 ~ 10-20 14:10，每次不超过 15 分钟	业务侧短时
KubePodNotReady	warning	spline-yolov8-train	全周期	镜像缺失，见 4.5
KubeMemoryOvercommit	warning	集群	全周期	内存 request 超配，实际使用约 9%，暂无风险

4.5 遗留问题跟踪

分级	问题	现状与证据	影响与建议
警告	K8s 控制平面证书	kube-apiserver 证书剩余 60 天（2026-12-26 到期），轮换已连续多期建议未落实	到期后 apiserver 不可用；建议本周确定窗口并启动变更审批
警告	178 个 Released PV	9444 GiB，数量与容量连续多期无变化	长期占用 NFS 容量；核查无引用后批量回收
警告	spline-yolov8-train 镜像缺失	Workflow 已存续 131 天，持续 ImagePullBackOff	持续触发告警；业务方补推镜像或下线任务
提示	Failed Pod 对象堆积	37 个（user3 36 个、qwen38 旧 Pod 1 个）	不占资源但干扰巡检；建议业务改用带 TTL 的 Job / Pipeline，或定期清理
提示	孤儿 PVC qwen36-cache	120 GiB，存续 118 天，无 Pod 挂载	确认后回收
提示	radar-* 停用资源	0 副本，PVC 200 GiB + NodePort 31891，存续 35 天	确认是否废弃后回收
提示	node02 磁盘水位	根分区 75.0%、/home/data 77.9%，与上期持平	继续观察，适时执行镜像垃圾回收
提示	Prometheus 保留期 10 天	10/14 事件的细粒度监控数据已过期，无法复盘	建议评估存储后延长至 30 天

4.6 补充（周期外）：更正上期对 10/14 事件的判断

上期报告将 10/14 node02 的 Ready 翻转归因于 node02 kubelet 层面。本次核对 Pod 状态发现，同日 10:31-10:34 master 上 kube-controller-manager、kube-scheduler（退出码 1）、kube-apiserver（退出码 137）以及 master 与 node02 的 node-exporter（退出码 143）相继重启，早于 node02 Ready 恢复时刻（11:20:45）约 46 分钟，说明当时控制平面同样出现了异常。

也正是在这次事件中，node02 上的工作负载迁移到了 node01（node02 Pod 数由 107 降至 22），形成了 10/23 的单点格局。由于 Prometheus 只保留 10 天，该时段的细粒度监控数据已过期，无法进一步还原。

4.7 镜像源治理复核

- local-path-provisioner helper 镜像仍指向 172.16.1.72:30002/library/busybox，本周期 PVC 供给正常
- Kyverno 策略 inject-kaniko-registry-mirror 状态 Ready（已部署 61 天）
- Harbor 健康检查全部组件 healthy，仓库 230 个、存储 199.31 GB（上期 188.46 GB）；6 个代理项目均在线
- 本周期无因外网镜像源导致的 ImagePullBackOff（业务私有镜像 csj-spine-base 除外）

5. 数据备份与安全巡检 (Backup & Security)

让客户对数据资产放心。

- Velero 集群备份：[OK] 正常（周期内 16 次全部 Completed，0 errors / 0 warnings；备份存储位置 default 状态 Available）
- pvc-daily-backup 7 次、minio-daily-backup 8 次、kubeflow-weekly-backup 1 次（10/25）
- 最近：pvc-daily-backup-20261026030022、minio-daily-backup-20261026040022（10/26 11:00 / 12:00 CST）
- 10/23 重启发生在当日备份完成之后，未影响备份任务；但 Velero 服务端及其 MinIO 均运行在 node01，重启期间备份服务不可用
- 仓库内现存有效备份 42 份
- MinIO 模型数据备份：[OK] 正常（每日执行，保留 30 天）
- K8s 证书检查：[!] kube-apiserver 证书剩余 60 天（2026-12-26 到期，CA 有效期至 2035 年），轮换窗口仍未确定
- cert-manager 管理的 6 张 Kubeflow webhook 证书均 Ready：kubeflow-trainer-cert 2026-12-11 到期，已排定 11-11 自动续期；其余 5 张 2027-01-20 到期
- 镜像扫描：Harbor Trivy 组件运行中（10/23 随 node01 重启后恢复），本周期未执行主动扫描

6. 下周工作计划 (Next Week's Plan)

- 暂无安排

- 报告生成时间：2026-10-26 18:04 CST
- 数据来源：kubectl（只读）、Prometheus API（node-exporter / DCGM / kube-state-metrics / ALERTS）、gpu-operator 组件日志（含 device-plugin 上一个容器实例）、nvidia-smi（经已有 dcgm-exporter Pod 执行）、Velero CR、cert-manager Certificate、Harbor API、openssl
- 证据目录：/home/storage/k8s-weekly-inspection/output/evidence-20261026/
- 缺失项：
- 数据统计截至 10/26 18:00，周期最后约 6 小时未覆盖
- 巡检不创建 Pod，故未读取节点 kern.log / syslog；10/23 重启"由人为发起"系依据 device-plugin 有序退出与无 cordon 记录推断，操作人与原因无法从系统日志确认
- Prometheus 保留期 10 天，10/14 事件细粒度数据已过期
- 两个 KubeContainerWaiting 的 user3 Pod 已被删除，等待原因无法追溯