维护周报-20261026

Kubeflow AI 平台运行周报

- 报告周期： 2026 年 10 月 19 日 - 2026 年 10 月 26 日
- 运维负责人： unix

本周重点

1. 10 月 23 日 14:20:07 worker-node01 重新进入 Ready。Istio 网关于 14:20:50 恢复，qwen38 于 14:21:55 恢复，Kubeflow Dashboard 于 14:27:13 恢复，Pipelines API 于 14:32:09 恢复，Loki 于 14:50:53 恢复。控制平面保持 Ready。
2. gpu-feature-discovery-44fkk 从 10 月 19 日 21:45 到 10 月 23 日 14:25 处于 CrashLoopBackOff，重启计数 1094。节点重新 Ready 后该 Pod 为 Running，计数没有再增加。
3. kube-apiserver 证书于 2026-12-26 到期，剩余 60 天。Released PV 仍为 178 个 / 9444 GiB。

1. 集群健康度概览 (Cluster Health Summary)

本模块用于给领导层快速浏览，展示系统整体稳定性。

- 集群可用率 (SLA)：控制平面本周期保持 Ready。worker-node01 的 Ready 条件于 10 月 23 日 14:20:07 重新成立。节点条件没有留下 NotReady 起点，不能给出中断秒数。
- 节点状态：巡检时 3/3 Ready（control-plane ×1，worker ×2），Kubernetes v1.32.10。
- 核心组件状态：
  1. Kubernetes 控制平面：[OK] 正常。etcd、kube-apiserver、kube-scheduler、kube-controller-manager 均为 1/1 Running，master 的 Ready 自 2025-12-26 起未变。
  2. Kubeflow Dashboard：[OK] 正常。centraldashboard 2/2 Running，容器于 10 月 23 日 14:27:13 重新启动。
  3. Istio 网关：[OK] 正常。istio-ingressgateway 1/1 Running，istio-proxy 于 10 月 23 日 14:20:50 重新启动。
  4. 监控系统 (Prometheus/Grafana)：[OK] 正常。Prometheus 与 Grafana 均为 Running，位于 master。
  5. 存储供给 (local-path-provisioner)：[OK] 正常。1/1 Running。该 Pod 在 10 月 23 日 14:19:54 随 node01 结束过一次，当前已恢复。
  6. 镜像仓库 (Harbor 代理缓存)：[OK] 正常。harbor-health.json 的 status 为 healthy，core、database、jobservice、portal、redis、registry、registryctl、trivy 均为 healthy。
  7. GPU 驱动：[OK] 正常。两台 worker 的 nvidia-device-plugin 与 nvidia-dcgm-exporter 均为 Running，DCGM 记录的驱动版本为 580.126.09。node01 当前 nvidia.com/gpu 可分配数量为 2。10 月 19 日至 23 日的 gpu-feature-discovery CrashLoop 见第 4 节。

2. 资源消耗统计 (Resource Utilization)

展示硬件利用率，帮助客户判断是否需要扩容。

资源类型	峰值利用率	周期平均利用率	峰值时剩余可用量
CPU	41.9%	3.0%	130 核
内存	11.6%	8.8%	0.57 TiB
GPU (NVIDIA)	100%	25.3%	2 张

资源类型	峰值利用率	周期平均利用率	峰值时剩余可用量
存储 (PV)	9.9%	8.7%	Bound 7005 GiB（6.84 TiB），Released 9444 GiB（9.22 TiB）待回收

CPU、内存和存储利用率的周期峰值都出现在 10 月 23 日 14:20，与 worker-node01 重新 Ready 的时刻相同。该时刻之外，CPU 最高 4.8%（10 月 26 日 00:10），内存最高 10.4%（10 月 22 日 22:35）。GPU 集群平均最高为 66.0%，出现在 10 月 20 日 09:45，当时 node02 的 GPU1 与 GPU3 为 0%，其余 4 张为 96% 或 100%。

节点详情：

节点	角色	CPU	内存使用	GPU	当前 Pod 数	根分区
master-node-storage-r620-g40	control-plane	56c	36.5%	0	21	48.8%
worker-node01-pro6000	worker	128c	9.7%	2 × RTX PRO 6000 Blackwell	117	38.4%
worker-node02-3090	worker	40c	10.0%	4 × RTX 3090	22	75.0%

当前 Pod 数为巡检时 Running 数量。

GPU 实际带载情况：

节点	GPU	显存占用	温度	功耗	带载业务
node01	GPU0	90028 MiB	32°C	84.47 W	未返回进程名
node01	GPU1	14876 MiB	47°C	318.16 W	未返回进程名
node02	GPU0	0 MiB	29°C	29.24 W	无进程
node02	GPU1	0 MiB	31°C	27.47 W	无进程
node02	GPU2	3055 MiB	70°C	271.56 W	进程名 [Not Found]
node02	GPU3	3055 MiB	73°C	275.15 W	进程名 [Not Found]

巡检时 node01 上 Running 且申请了 GPU 的 Pod 是 qwen38-27b-mtp（1 卡）和 of-ab-flash-formal-20261025-v1-b-3（1 卡）。node02 上是 of-ab-flash-formal-20261025-v1-a-5（2 卡）和 csj-spine-detection（1 卡）。node01 的 nvidia-smi 没有返回进程行，不能把 Pod 对应到 GPU0 或 GPU1。node02 GPU1 的利用率在整个周期都是 0%。

PV 状态：

PV 状态	数量	容量	较上期
Bound	55	7005 GiB（6.84 TiB）	+2 个 / +200 GiB
Released	178	9444 GiB（9.22 TiB）	无变化

上期周报的 Bound 数字是 PVC 53 个 / 6805 GiB。本次 Bound PVC 与 Bound PV 都是 55 个 / 7005 GiB。本周期新创建 4 个 PVC、合计 400 GiB，净增只有 200 GiB，说明另有卷减少；本次没有逐个核对减少的卷。

Bound 按存储类：nfs-csi-ssd 4837 GiB，nfs-csi 1108 GiB，nfs-csi-kubeflow 580 GiB，local-path 380 GiB，local-prometheus 100 GiB。

3. AI 业务运行数据 (AI Workflow Stats)

体现 Kubeflow 平台的实际产出。

- Notebook 运行数：注册 9 个，Running 6 个。

1. kubeflow-user-example-com/style-big，worker-node02-3090
2. kubeflow-user-example-com/vs，worker-node02-3090
3. user2-example-com/mni-test-0104，worker-node01-pro6000
4. user2-example-com/mni-test-qw-260106，worker-node01-pro6000
5. user4-example-com/awgs-builder，worker-node01-pro6000
6. user5-example-com/csj-spine-detection，worker-node02-3090

• 未找到 Notebook Pod 的 3 个是 user3-example-com/nndet-v2、user3-example-com/nndetection、user3-example-com/p60001。

• Pipeline 运行数：

1. 巡检时仍保留的 Workflow 42 个：成功 37、失败 2、错误 2、运行中 1。
2. 运行中的 user5-example-com/spline-yolov8-train-sj7sw 已存在 131 天，不是本周期新建，其训练 Pod 仍为 Pending。
3. 失败是 user3-example-com/ofab-cpu-inline-fjsrf 与 pengwin-of-ab-formal-20261024-flash-status-a-extra-amp-accl89nn。错误是同组 flash-status 的 custodyqx4cx 与 failurem7mzp。
4. 其余成功记录的年龄都不超过 23 小时，落在 10 月 26 日。已经从集群删除的运行没有计入。

• KServe 模型推理：

1. kubeflow-user-example-com/qwen38-27b-mtp：Ready。预测 Pod 在 worker-node01-pro6000 上 Running，容器于 10 月 23 日 14:21:55 启动。
2. kubeflow-user-example-com/detect-digits-2：Ready。未发现对应 Running Pod。

PVC 名称	命名空间	创建时间	用途
pengwin-task3-beta-inputs-20261019-v1	user3-example-com	2026-10-19 16:58	未证实
pengwin-task3-beta-results-20261019-v1	user3-example-com	2026-10-19 16:58	未证实
pengwin-of-ab-inputs-20261024-v1	user3-example-com	2026-10-24 18:19	未证实
pengwin-of-ab-results-20261024-v1	user3-example-com	2026-10-24 18:19	未证实

4 个 PVC 均为 Bound，每个 100 GiB，存储类 nfs-csi-ssd。

4. 故障处理与告警记录 (Incidents & Alerts)

4.1 【严重】worker-node01 于 10 月 23 日重新就绪，节点上的平台组件中断后恢复

现象： 10 月 23 日 14:19:54，worker-node01 上的一批容器以 Unknown 结束。14:20:07 该节点重新 Ready。Istio 网关于 14:20:50 恢复，qwen38 于 14:21:55 恢复，Dashboard 于 14:27:13 恢复，Pipelines API 于 14:32:09 恢复，Loki 于 14:50:53 恢复。控制平面没有中断。

影响： 调度在 worker-node01 上的入口和推理服务出现一次中断。Dashboard 从节点重新 Ready 起约 7 分钟恢复，Pipelines API 约 12 分钟恢复，Loki 约 31 分钟恢复。NotReady 起点没有留在节点条件里。

证据：

1. nodes.json 中 worker-node01 的 Ready 条件时间为 2026-10-23T06:20:07Z。master 的 Ready 时间仍为 2025-12-26T05:29:16Z。
2. pods.json 中 124 条落在本周期的容器结束记录，主要原因为 Unknown，时间集中在 2026-10-23T14:19:54+08:00。
3. 上述组件的容器 startedAt 分别为 14:20:50、14:21:55、14:27:13、14:32:09、14:50:53（CST）。

4. alerts.json 在同一窗口有 Loki 副本不一致（14:35–14:50）、fluent-bit 滚动卡住（14:45–14:50）和 metrics.k8s.io 一个采样点不可用（14:25）。

核查项	核查方法	结果
节点是否重新就绪	nodes.json 的 Ready 条件	worker-node01 于 10-23 14:20:07 重新 Ready
控制平面是否中断	master 的 Ready 条件与控制平面 Pod	Ready 自 2025-12-26 起未变，4 个控制平面 Pod 均为 Running
入口与推理恢复时刻	pods.json 容器 startedAt	Istio 14:20:50，qwen38 14:21:55，Dashboard 14:27:13，Pipelines API 14:32:09，Loki 14:50:53
GPU 是否仍可分配	nodes.json allocatable 与 nvidia-smi	node01 可分配 2 张，两张卡都返回了显存、温度和功耗

建议：

1. 核对 worker-node01 在 2026-10-23 14:15 至 14:20 的主机与 kubelet 日志，写出重启原因。完成标准：原因已记录，或确认这段日志已经不存在。

4.2 【警告】gpu-feature-discovery 在节点重启前持续 CrashLoopBackOff

1. 【警告】gpu-operator/gpu-feature-discovery-44fkk 从 10 月 19 日 21:45 到 10 月 23 日 14:25 处于 CrashLoopBackOff，最后一次退出为 14:15:49、原因 Error、重启计数 1094。同期 gpu-feature-discovery DaemonSet 从 10 月 19 日 21:45 到 10 月 23 日 14:15 滚动卡住。节点重新 Ready 后该 Pod 为 1/1 Running，计数没有再增加。这段时间 node01 的 GPU 利用率序列仍有数据。

4.3 告警汇总

Watchdog 与 InfoInhibitor 不列入。内存超卖告警不列入：同期集群内存使用最高 11.6%，节点最高 36.5%，剩余内存没有接近 kubelet 的 memory.available 硬阈值 100Mi。Pipeline 系统容器的 PodInitializing 告警集中在 10 月 25 日 02:50 至 10 月 26 日 05:00，未看到平台组件中断，不列入。若干 Pengwin 检查 Pod 的 NotReady 只有 1 到 4 个采样点，不列入。

	时段 (CST)	关联事件	原因
erator/gpu-feature-discovery-44fkk	10-19 21:45 至 10-23 14:25	同期 DaemonSet gpu-feature-discovery 滚动卡住。本周期 Events 已滚动，没有留下对应事件	CrashLoopBackOff，最后一次退出原 Error，重启计数 1094
example-com/spline-yolov8-train-sj7sw-train-103964838	10-19 00:00 至 10-26 23:55	周期结束后 10-27 03:26 仍有 ImagePullBackOff。周期内的事件对象已滚动	内网镜像 172.16.1.72:30002/private_library/c 不存在
g/loki	10-23 14:35 至 10-23 14:50	与 node01 上容器在 14:19:54 成批结束相接。对应 Events 已滚动	节点重新就绪后副本短暂不一致
g/fluent-bit	10-23 14:45 至 10-23 14:50	与 node01 重新 Ready 的同一窗口。对应 Events 已滚动	DaemonSet 滚动短暂卡住

	时段 (CST)	关联事件	原因
1.metrics.k8s.io	10-23 14:25	与 node01 重新 Ready 同一分钟。对应 Events 已滚动	聚合 API 有一个采样点不可用

4.4 遗留问题跟踪

分级	问题	持续时长	较上期变化	建议
警告	spline-yolov8-train 因私有镜像不存在一直 Pending	自 10-14 11:21 至本周期结束，约 12 天	本周期全程未就绪	补推 csj-spine-base:v1.0，或删除该 Workflow 与 Pending Pod
提示	Released PV 178 个，占用 9444 GiB	本周期数量和容量都没有变化	与上期周报相同	确认没有引用后再回收
提示	worker-node02 根分区周期峰值 75.0%	本周期	上期周报同为 75.0%	下周继续记录该节点根分区使用率

4.5 镜像源治理复核

1. 现存 ImagePullBackOff 只有 user5-example-com/spline-yolov8-train-sj7sw-train-103964838，镜像位于内网 172.16.1.72:30002/private_library，仓库返回 not found。没有发现外网镜像源的拉取失败。

2. Kyverno 的 admission、background、cleanup、reports 四个控制器均为 1/1 Running。本次没有单独采集策略对象名称。

3. Harbor 健康检查为 healthy，其中 trivy 为 healthy。10 月 23 日 14:19 前后 Harbor 各组件随 node01 结束过一次，巡检时均为 Running。

5. 数据备份与安全巡检 (Backup & Security)

让客户对数据资产放心。

- Velero 集群备份：本周期仍保留的备份 16 次，全部 Completed，errors 为空。
- MinIO 模型数据备份：[OK] 正常。minio-daily-backup 在本周期保留 8 次，全部 Completed。
- K8s 证书检查：kube-apiserver 于 2026-12-26 04:51:48 GMT 到期，自 2026-10-27 03:33 起剩余 60 天。cert-manager 证书均为 Ready。其中最早到期的是 kubeflow/kubeflow-trainer-cert，notAfter 为 2026-12-11 07:38:35Z，剩余 45 天，renewalTime 为 2026-11-11 07:38:35Z。
- 镜像扫描：Harbor trivy 组件为 healthy。本次没有触发漏洞扫描，没有扫描结果。

备份计划	周期 (UTC)	保留策略	本周期执行
pvc-daily-backup	0 3 * * *	TTL 168h	7
minio-daily-backup	0 4 * * *	TTL 720h	8
kubeflow-weekly-backup	0 2 * * 0	TTL 720h	1

pvc-daily-backup 在 10 月 19 日 03:00 UTC 的那次不在当前列表中。168 小时保留已经盖不住这个时间点，不能据此写成失败。最近一次仍保留的 MinIO 备份是 minio-daily-backup-20261026040022。

磁盘使用率的周期峰值：master 48.8%，worker-node01 38.4%，worker-node02 75.0%。

6. 上期落实

上期无待落实计划

7. 下周计划 (Next Week's Plan)

序号	计划事项	对象	完成标准
1	核对 10 月 23 日 14:15 至 14:20 的重启原因	worker-node01	写出原因，或确认对应日志已经不存在
2	确认重启计数是否仍为 1094	gpu-operator/gpu-feature-discovery-44fkk	计数未增加，或记录新的退出原因
3	处理训练镜像缺失	user5-example-com/spline-yolov8-train	镜像可以拉取，或 Workflow 与 Pending Pod 已删除

- 报告生成时间：2026-10-27 03:33 CST
- 数据来源：kubectl 只读采集、Prometheus、Velero Backup 与 Schedule、Harbor /api/v2.0/health、已有 dcgm-exporter Pod 上的 nvidia-smi、cert-manager Certificate、kube-apiserver 证书、节点 kubelet 只读配置
- 证据目录：/home/storage/k8s-weekly-inspection/output/evidence-20261026/
- 缺失项：
  1. Kubernetes Events 只剩周期结束之后的少量对象，第 4 节不能用事件还原 10 月 19 日至 23 日的过程，告警时段以 Prometheus 为准。
  2. 没有采集节点内核日志，第 4 节写不出 worker-node01 的重启原因，也没有 Xid 判定。
  3. node01 的 nvidia-smi 没有返回 compute-apps 进程名，第 2 节不能把 GPU 对应到具体 Pod。
  4. 已从集群删除的 Workflow 不在本次列表中，第 3 节只统计巡检时仍保留的 42 个对象。
  5. Prometheus 存储利用率原先写入 storage.json，随后被 PVC/PV JSON 覆盖；同一查询已补存为 storage-prom.json，第 2 节存储利用率使用这份结果。