维护周报-20260921

# Kubeflow AI 平台运行周报

| | |
|---|---|
| 报告周期 | 2026 年 09 月 14 日 - 2026 年 09 月 21 日 |
| 运维负责人 | unix |
| 生成时间 | 2026-09-22 16:56:29 |

本周重点： 上周报告的 GPU 掉总线故障（Xid 79）本周期内未再复发。9 月 18 日对 worker-node01 执行了一次计划内停机维护（约 66 分钟），此后节点已稳定运行 4 天。同期新业务 radar-inference-api-v2 上线并占用该节点第二张 GPU，双卡已恢复带载运行。

## 1. 集群健康度概览 (Cluster Health Summary)

本模块用于给领导层快速浏览，展示系统整体稳定性。

● 集群可用率 (SLA)：约 99.6%（仅 9 月 18 日计划内维护停机 66 分钟，无非计划宕机）
● 节点状态：3/3 Ready（Master x1, Worker x2）
● 核心组件状态：
○ Kubernetes 控制平面 (v1.32.10)： 正常
○ Kubeflow Dashboard： 正常（随 9/18 维护重建，当前 0 重启）
○ Istio 网关： 正常（驻留 worker-node02，已稳定 11 天）
○ 监控系统 (Prometheus/Grafana)： 正常
○ 存储供给 (local-path-provisioner)： 正常
○ 镜像仓库 (Harbor 代理缓存)： 正常
○ GPU 驱动 (NVIDIA 580.126.09)： 正常，本周期无 Xid 错误

## 2. 资源消耗统计 (Resource Utilization)

| 资源类型 | 峰值利用率 | 高峰期平均利用率 | 高峰期剩余可用量 |
|---|---|---|---|
| CPU | ~7.6% | ~1.8% | 约 219 核 |
| 内存 | ~16.4% | ~7.9% | 约 0.59 TiB |
| GPU (NVIDIA) | 100% | 1.9% | 约 3 张 |
| 存储 (PVC) | ~8.1% | ~5.9% | 约 14.47 TiB |

| 节点 | 角色 | CPU | GPU | Pod 数 |
|---|---|---|---|---|
| master-node-storage-r620-g40 | control-plane | 56c | 0 | 21 |
| worker-node01-pro6000 | worker | 128c | 2x PRO 6000 (96GB) | 30 |
| worker-node02-3090 | worker | 40c | 4x RTX 3090 (24GB) | 107 |

● GPU 占用回升至 3 张：qwen38-27b-mtp（node01 GPU0，90.3 GB）、radar-inference-api-v2（node01 GPU1，15.9 GB）、csj-spine-detection（node02）
● 存在明显的节点负载倾斜：worker-node02 承载 107 个 Pod，内存已达 52%；worker-node01 仅 30 个 Pod，内存 10%
● 倾斜成因：9/18 维护期间 worker-node01 上的工作负载被驱逐至 node02，维护结束后未自动回迁
● PVC 总量由 14619 GiB 增至 14819 GiB（新增约 200 GiB，来自新业务）

## 3. AI 业务运行数据 (AI Workflow Stats)

● Notebook 运行数：本周活跃 6 个，状态 Ready
○ kubeflow-user-example-com/style-big
○ kubeflow-user-example-com/vs

○ user2-example-com/mni-test-0104
○ user2-example-com/mni-test-qw-260106
○ user4-example-com/awgs-builder
○ user5-example-com/csj-spine-detection
● Pipeline 运行数：成功 0 次，失败 0 次（本周无新增 Pipeline Run 记录）
● KServe 模型推理：在线模型 2 个，全部 Ready
○ detect-digits-2
○ qwen38-27b-mtp
● 本周新增业务：radar-inference-api-v2（09-21 上线，独立 Deployment 形式，占用 worker-node01 GPU1）
○ 该服务未纳入 KServe 管理，建议后续统一接入 InferenceService 以获得自动扩缩与版本灰度能力

## 4. 故障处理与告警记录 (Incidents & Alerts)

### 4.1 上周 GPU 故障的闭环跟踪

结论：本周期（09-14 至 09-21）未发生任何 Xid 错误，故障未复发。

| 时间 (CST) | 事件 | 性质 |
|---|---|---|
| 09-10 15:50 | GPU 0 报 Xid 79 掉总线，两卡置 Node Reboot Required | 非计划，异常宕机 |
| 09-11 13:13 | GPU 1 报 Xid 79 掉总线，两卡置 Node Reboot Required | 非计划，异常宕机 |
| 09-18 09:42 | 系统有序停止各项服务（OpenIPMI、OpenVPN、PackageKit 等） | 计划内维护 |
| 09-18 10:48 | 节点启动完成，停机时长约 66 分钟 | 维护结束 |

判定依据：9/10 与 9/11 两次重启，系统日志在 kubelet 输出中戛然而止，无任何服务停止序列，属异常宕机；而 9/18 的日志中存在 systemd (PID 1) 逐项停止服务的完整序列，属正常关机。66
分钟的停机时长与现场硬件检修相符。
当前状态：
○ 节点已连续稳定运行 4 天，无 Xid、无重启
○ 两张 GPU 均在线并带载：温度 28°C / 29°C，功耗 83 W / 82 W，累计未修正 ECC 错误 0
○ 驱动版本 580.126.09 未变更，说明本次维护为硬件侧处置而非驱动升级
后续建议：
1. 上周故障由 vLLM 高负载触发，而 radar-inference-api-v2 上线后双卡已恢复同时带载，建议重点观察未来 1-2 周双卡满载工况下是否复现，这是验证维护效果的关键窗口
2. 若已取得 BMC/iDRAC 的 SEL 硬件日志，建议归档留存，作为后续判断的基线
3. 建议为 GPU Xid 错误配置 Prometheus 告警规则（基于 DCGM
指标），实现故障即时发现而非依赖周巡检回溯

### 4.2 常规告警与遗留问题

● 关键告警总数：当前 firing 4 条（上周 3 条）；本周期 Warning 事件 0 条
● 异常 Pod 统计：全集群仅 user5-example-com 1 个
● [持续 97 天] spline-yolov8-train 镜像拉取失败 (ImagePullBackOff)
- 私有镜像 csj-spine-base:v1.0 在内网 Harbor 中确认不存在；属业务侧从未推送，建议限期补推或下线

● [持续] 孤儿 PVC qwen36-cache（120Gi）
- qwen36-27b-mtp 下线已超一周，该卷仍 Bound 且无 Pod 挂载，建议确认后回收

● [新增] 节点负载倾斜
- worker-node02 承载 107 个 Pod（内存 52%），worker-node01 仅 30 个（内存 10%）
- 建议在业务低峰期对无状态负载执行滚动重启，促使调度器重新均衡

### 4.3 镜像源治理成果复核

● local-path-provisioner helper 镜像持续指向内网 Harbor，PVC 供给正常

● Harbor 代理缓存项目与 Kyverno 策略 inject-kaniko-registry-mirror 均运行正常
● 9/18 维护重启后，全部工作负载镜像正常拉取，无 ImagePullBackOff，镜像内网化改造再次通过实战检验

## 5. 数据备份与安全巡检 (Backup & Security)

● Velero 集群备份： 正常（本周期 15 次任务全部 Completed，失败 0 次）
○ kubeflow-weekly-backup-20260920020003 — Completed (0 errors, 0 warnings)
○ minio-daily-backup-20260921040004 — Completed (0 errors, 0 warnings)
○ pvc-daily-backup-20260921030004 — Completed (0 errors, 0 warnings)
○ 9/18 维护停机期间的备份任务未受影响（当日 03:00/04:00 UTC 任务均在停机前完成）
● MinIO 模型数据备份： 正常（保留 30 份，TTL 720 小时）
● K8s 证书检查：剩余有效期 96 天（证书统一于 2026-12-26 到期，CA 有效期至 2035 年）
○ 提示：有效期已进入 100 天以内，建议在 11 月前安排证书轮换窗口
● 镜像扫描：Harbor Trivy 组件运行中，本周未执行主动扫描

## 6. 下周工作计划 (Next Week's Plan)

● 暂无安排

---

报告生成时间：2026-09-22 16:56 CST
数据来源：kubectl、Prometheus API、Velero CR、节点内核日志 (kern.log/syslog)、nvidia-smi、Harbor API