维护周报-20261012

Kubeflow AI 平台运行周报

- 报告周期： 2026 年 10 月 05 日 - 2026 年 10 月 12 日
- 运维负责人： unix

本周重点： 9 月 GPU 掉总线故障（Xid 79）的观察期已圆满结束。worker-node01 自 9 月 18 日维护后连续稳定运行 24 天，期间零 Xid 错误、零重启、ECC 零错误，该故障判定为闭环。

本周期集群无任何宕机，SLA 100%，无新增故障。

需要关注的是：上期工作计划中的 178 个 Released PV（9.22 TiB）回收尚未执行，同时控制平面证书剩余有效期已降至 75 天，轮换窗口趋紧。

1. 集群健康度概览 (Cluster Health Summary)

本模块用于给领导层快速浏览，展示系统整体稳定性。

- 集群可用率 (SLA)：100%（本周期无计划内及非计划停机，无节点重启）
- 节点状态：3/3 Ready（Master x1, Worker x2）
- 核心组件状态：
- Kubernetes 控制平面 (v1.32.10)：[OK] 正常（etcd / apiserver / scheduler / controller-manager 全部 Running）
- Kubeflow Dashboard：[OK] 正常（已稳定 24 天）
- Istio 网关：[OK] 正常（已稳定 30 天）
- 监控系统 (Prometheus/Grafana)：[OK] 正常（已稳定 167 天）
- 存储供给 (local-path-provisioner)：[OK] 正常（已稳定 47 天）
- 镜像仓库 (Harbor 代理缓存)：[OK] 正常（6 个代理项目全部在线）
- GPU 驱动 (NVIDIA 580.126.09)：[OK] 正常，本周期无 Xid 错误

2. 资源消耗统计 (Resource Utilization)

展示硬件利用率，帮助客户判断是否需要扩容。

资源类型	峰值利用率	周期平均利用率	峰值时剩余可用量
CPU	~7.0%	~2.3%	约 208 核
内存	~21.3%	~9.2%	约 0.56 TiB
GPU (NVIDIA)	100%	~5.2%	4 张（6 张中 2 张被调度占用，其中 1 张空载）
存储 (PV)	~8.4%	~7.6%	Bound 6.13 TiB，另有 Released 9.22 TiB 待回收

节点详情：

节点	角色	CPU	内存使用	GPU	当前 Pod 数	根分区
master-node-storage-r620-g40	control-plane	56c	27%	0	21	48.5%

节点	角色	CPU	内存使用	GPU	当前 Pod 数	根分区
worker-node01-pro6000	worker	128c	12%	2x RTX PRO 6000 Blackwell (96GB)	30	38.1%
worker-node02-3090	worker	40c	45%	4x RTX 3090 (24GB)	107	74.8%

GPU 实际带载情况（本周期无变化）：

节点	GPU	显存占用	温度	功耗	带载业务
node01	GPU0	90844 MiB	28	82 W	qwen38-27b-mtp
node01	GPU1	14 MiB	22	33 W	空闲
node02	GPU0-3	0 MiB	22-26	25-29 W	全部空闲

• 全集群实际仅 1 张 GPU 真正带载。csj-spine-detection 虽在调度层占用 node02 一张 3090，但 nvidia-smi 显示 0 MiB、无进程，属占位空载，与上期结论一致

• 存储总量：PV 共 221 个 / 15719 GiB，较上期 14819 GiB 增加 900 GiB

PV 状态	数量	容量	较上期
Bound	43	6275 GiB (6.13 TiB)	+5 个 / +900 GiB（新业务数据卷）
Released	178	9444 GiB (9.22 TiB)	无变化，回收未执行

• Bound 卷按存储类分布：nfs-csi-ssd 4107 GiB、nfs-csi 1108 GiB、nfs-csi-kubeflow 580 GiB、local-path 380 GiB、local-prometheus 100 GiB

• 节点负载倾斜依然存在：worker-node02 承载 107 个 Pod（上期 109），worker-node01 仅 30 个，倾斜格局未改变，回迁操作未执行

3. AI 业务运行数据 (AI Workflow Stats)

体现 Kubeflow 平台的实际产出。

• Notebook 运行数：注册 9 个，本周活跃 6 个，状态均为 Running

• kubeflow-user-example-com/style-big、kubeflow-user-example-com/vs

• user2-example-com/mni-test-0104、user2-example-com/mni-test-qw-260106

• user4-example-com/awgs-builder、user5-example-com/csj-spine-detection

• 其余 3 个（user3 的 nndet-v2、nndetection、p60001）处于休眠状态，属正常资源回收

• Pipeline 运行数：本周期恢复活跃，新增 Pod 5 个，成功 4 个、运行中 1 个、失败 0 个

• user3-example-com/pengwin-fragment-labels-full-import-20261010-v1 运行中（已执行约 2 小时），各 DAG 子任务（driver / impl）正常流转

• 这是连续两个周期（9/21-9/30 均为 0 次）后首次出现新的 Pipeline Run，平台使用率回升

• KServe 模型推理：在线模型 2 个，全部状态 Ready

• qwen38-27b-mtp（在线服务，实际带载）

• detect-digits-2（Ready，replicas 已缩容为 0）

• 新增业务数据卷 5 个，反映 user3 团队本周期有密集的新项目启动：

PVC 名称	命名空间	创建时间	用途推测
xray2pelvic-r2-migration-20261006	user3-example-com	10-05	数据迁移

PVC 名称	命名空间	创建时间	用途推测
deepsdf-dictionary-migration-20261006	user3-example-com	10-05	数据迁移
pengwin-multitask-20261009-v1	user3-example-com	10-08	多任务训练
pengwin-fragment-labels-20261010-v1	user3-example-com	10-10	标注数据导入
pengwin-fragment-train-20261010-v1	user3-example-com	10-10	训练数据集

• radar-inference-api-v2（9/23 缩容至 0）本周期仍保持 0 副本，未重新拉起。

其配套资源仍完整保留：Service radar-inference-v2、NodePort radar-inference-v2-nodeport(31891)、PVC radar-model-cache(100 GiB) 与 radar-workspace(100 GiB)。

建议向业务方确认是临时停用还是已废弃，若废弃可回收 200 GiB 存储与 1 个 NodePort

4. 故障处理与告警记录 (Incidents & Alerts)

展示你的专业性，以及你解决了哪些隐患。

4.1 GPU 掉总线故障正式闭环

结论：9/18 维护后已连续 24 天零故障，本周期零 Xid，该故障判定为闭环。

核查项	核查方法	结果
是否再发生 Xid 错误	遍历 node01 现存及归档内核日志（覆盖 9/13 至 10/12）	0 条
是否再发生重启	/proc/uptime	开机 24.0 天（9/18 至今未重启）
是否存在其它硬件错误	检索 Machine Check / Hardware Error / EDAC / Uncorrected	0 条
GPU ECC 健康度	nvidia-smi 累计未修正 ECC 错误	GPU0 / GPU1 均为 0
是否有待重启的内核更新	/var/run/reboot-required 及 /boot 内核镜像	无待重启项，运行内核 6.8.0-90 为唯一已装内核

重要提醒：闭环结论存在一个前提限制。 故障原始触发条件是 vLLM 驱动双卡高负载，

而自 9/23 radar-inference-api-v2 缩容后，node01 GPU1 一直空闲，24 天的稳定期从未复现"双卡同时满载"工况。

因此本次闭环可确认"硬件维护未引入新问题、空载/单卡工况稳定"，但尚不能完全排除高负载下复发的可能。

若后续有新 LLM 服务上线，建议优先调度至 node01 GPU1 并把其后 1-2 周作为补充验证窗口。

巡检方法修正：本次统计节点启动次数时，日志中出现 9 月 30 日 19:53 前后 3 条疑似启动记录，

但 uptime 显示其间并无重启。追查原文后确认为误报——这些是 kubelet 将某个诊断 Pod 的命令行文本

写入了 syslog，而该命令行中恰好包含 Linux version 字样。

> 后续巡检应使用 grep 'kernel: Linux version' 限定内核来源，并始终以 /proc/uptime 交叉验证。

4.2 上期工作计划落实情况

上期（9/30）报告列出 7 项计划，本次核查结果如下：

上期计划事项	状态	核查依据
排期 K8s 证书轮换	[X] 未执行	证书仍为 2026-12-26 到期，剩余 75 天
回收 178 个 Released PV（~9.2 TiB）	[X] 未执行	Released PV 仍为 178 个 / 9444 GiB，数量容量均无变化
回收孤儿 PVC qwen36-cache（120 GiB）	[X] 未执行	仍为 Bound 状态，已存续 103 天

上期计划事项	状态	核查依据
跟进 csj-spine-base:v1.0 补推或下线任务	[X] 未执行	spline-yolov8-train 仍 ImagePullBackOff，已阻塞 116 天
node02 滚动重启缓解 Pod 倾斜	[X] 未执行	node02 仍 107 Pod，KubeletTooManyPods 持续触发
排查 node02 磁盘水位	[!] 部分	/home/data 维持 77.6%，根分区由 73.0% 升至 74.8%，仍在缓慢增长
radar 重新启用后观察双卡稳定性	— 不适用	radar 未重新启用，无观察样本

说明：上述事项均为需要业务方确认或需停机窗口的操作，非平台侧可单方面执行。

建议优先推动证书轮换与 Released PV 回收两项——前者有硬性时间约束，后者可释放 9.2 TiB 存储。

4.3 常规告警与遗留问题

- 关键告警：当前 firing 4 条（周期内平均 6 条、峰值 12 条），无 critical 级别，与上期持平

告警名称	级别	对象	说明
Watchdog	none	—	监控链路自检，设计上长期触发，非故障
KubeMemoryOvercommit	warning	集群	内存 request 总和超单节点容量，实际使用仅 9.2%，暂无风险
KubePodNotReady	warning	spline-yolov8-train	见下方遗留问题
KubeletTooManyPods	info	worker-node02	Pod 数接近单节点上限，由负载倾斜导致

遗留问题跟踪：

问题	持续时长	较上期变化	建议
spline-yolov8-train 镜像拉取失败	116 天	+11 天，持续恶化	私有镜像 csj-spine-base:v1.0 在 Harbor 中确认不存在，属业务侧从未推送；建议限期补推或下线任务
178 个 Released PV 占用 9.22 TiB	—	无变化	回收策略为 Retain，NFS 数据目录不会自动清理；核查无引用后批量回收
孤儿 PVC qwen36-cache (120 GiB)	103 天	无变化	建议确认后回收
radar-* 零副本资源 (200 GiB + NodePort)	20 天	无变化	与业务方确认是否废弃
节点负载倾斜 (107 vs 30 Pod)	24 天	109→107，无实质改善	低峰期滚动重启无状态负载促使重新调度
node02 磁盘水位	—	根分区 73.0%→74.8%	镜像层占 153 GB，建议执行镜像垃圾回收

- 累计可回收存储约 9.53 TiB（Released PV 9.22 TiB + qwen36-cache 120 GiB + radar-* 200 GiB）
- 异常 Pod 统计：全集群仅 user5-example-com 1 个
- 容器重启计数 Top：kubeflow/metadata-writer 107 次（长期累计值，当前 Running 稳定），

其余均为 GPU Operator 与 CNI 组件的历史累计，本周期内无新增重启

4.4 镜像源治理成果复核

- local-path-provisioner helper 镜像持续指向内网 Harbor（172.16.1.72:30002/library/busybox），PVC 供给正常
- 本周期新建 5 个 PVC 全部供给成功，是对该改造的又一次实战检验
- Kyverno 策略 inject-kaniko-registry-mirror 运行正常（Ready，已部署 47 天）
- Harbor 代理缓存项目全部在线，仓库数由 208 增至 224，存储用量 185.71 GB

代理项目	缓存仓库数
dockerhub	33
gcr	14
ghcr	4
k8s	2
nvcr	1
quay	1

- 本周期全集群无任何因外网镜像源导致的 ImagePullBackOff（业务侧 csj-spine-base 除外），镜像内网化改造持续有效

5. 数据备份与安全巡检 (Backup & Security)

让客户对数据资产放心。

- Velero 集群备份：[OK] 正常（本周期 15 次任务全部 Completed，失败 0 次，0 warnings）

备份计划	周期 (UTC)	保留策略	本周期执行
pvc-daily-backup	每日 03:00	TTL 168h / 保留 7 份	7 次
minio-daily-backup	每日 04:00	TTL 720h / 保留 30 份	7 次
kubeflow-weekly-backup	每周日 02:00	TTL 720h / 保留 30 份	1 次

- 最近一次：minio-daily-backup-20261011040031 — Completed (0 errors)
- 当前仓库中共保留 42 份有效备份
- 说明：备份 cron 按 UTC 执行（03:00 UTC = 11:00 CST），10/12 当日任务尚未到执行时间，属正常
- MinIO 模型数据备份：[OK] 正常
- K8s 证书检查：控制平面证书剩余有效期 75 天（统一于 2026-12-26 到期，CA 有效期至 2035 年）
- [!] 较上期减少 11.7 天。上期建议的"10 月内排定轮换窗口"尚未落实，本月仅剩约 2.5 周，建议本周内确定轮换时间并启动变更审批，避免临近到期仓促操作
- 节点磁盘水位：worker-node02 根分区 74.8%（较上期 +1.8 个百分点，持续缓慢增长），/home/data 维持 77.6%
- 容器镜像层占用 153 GB，建议执行一次镜像垃圾回收
- 超过 80% 将触发 kubelet 镜像驱逐，按当前增速约 2 个月内触及阈值
- 镜像扫描：Harbor Trivy 组件运行中，本周未执行主动扫描

6. 下周工作计划 (Next Week's Plan)

- 暂无安排

- 报告生成时间：2026-10-12 10:52 CST
- 数据来源：kubectl、集群内 Prometheus API（DCGM / node-exporter）、Velero CR、Harbor API、节点内核日志 (kern.log / syslog 含归档)、nvidia-smi、openssl s_client
- 中间数据：maintenance_weekly_report_data_20261012.json
- 备注：上一期报告覆盖至 2026-09-30，本期覆盖 10-05 起，其间 10-01 至 10-04 为国庆假期，未单独出具报告